

# 时间序列分析 (TIME SERIES ANALYSIS)

主讲：吴尚

复旦大学管理学院统计与数据科学系

# MA模型识别


$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2}, k = 1, 2, \dots$$

- 对于白噪声(MA(0)), 当 $k > 0$ 时,  $Var(r_k) \approx \frac{1}{n}$
- 对于MA(q), 当 $k > q$ 时,  $Var(r_k) \approx \frac{1}{n} \left[ 1 + 2 \sum_{j=1}^q \rho_j^2 \right]$
- $r_k$ 在正负2倍的标准差 $\pm 2\hat{s}_q$ 之间的概率约为0.95, 其中

$$\hat{s}_q = \sqrt{\frac{1}{n} \left[ 1 + 2 \sum_{j=1}^q r_j^2 \right]}$$

- 先判断序列是否为白噪声, 再依次判断是否为MA(1), MA(2), ……


# MA(1)模型识别范例



```
> acf(ma1.1.s, ci.type='ma', xaxp=c(0, 20, 10))
```

# MA(2)模型识别范例

该红线是用  
于判断是否  
为MA(1)模型



```
> acf (ma2.s, ci.type='ma', xaxp=c(0,20,10))
```

# 偏自相关函数 (PACF)

- 对于任意平稳序列, 已知 $\rho_1, \rho_2, \dots$ , 对于给定的 $k$ , 考虑方程组

$$\rho_1 = \phi_{k1} + \phi_{k2}\rho_1 + \dots + \phi_{kk}\rho_{k-1}$$

$$\rho_2 = \phi_{k1}\rho_1 + \phi_{k2} + \dots + \phi_{kk}\rho_{k-2}$$

$$\vdots$$

$$\rho_k = \phi_{k1}\rho_{k-1} + \phi_{k2}\rho_{k-2} + \dots + \phi_{kk}$$

- 我们把 $\{\phi_{kk}\}$ 称为 偏自相关函数 (PACF) 序列, 有如下重要结论:
- 对于AR(p)过程, 当 $k \geq p$ 时,

$$\phi_{kj} = \begin{cases} \phi_j & j = 1, \dots, p \\ 0 & j = p + 1, \dots, k \end{cases}$$

- 特别地,  $\phi_{pp} = \phi_p \neq 0, \phi_{kk} = 0, k > p$ , 即AR(p)过程的偏自相关函数序列 $p$ 阶截尾。


# 样本偏自相关函数

- 前面所定义的偏自相关函数都是基于序列的性质，由其内在的自相关函数计算得出（与自相关函数类似，是模型本身的参数）；当我们有具体样本数值时，可以用样本自相关函数 $r_k$ 代替 $\rho_k$ 来计算，例如求解方程组、递推式等，记为 $\hat{\phi}_{kk}$ .
- 由于AR(p)过程的PACF序列 $p$ 阶截尾，当 $k > p$ 时， $\phi_{kk} = 0$ ，所以 $\hat{\phi}_{kk}$ 应该也接近0，实际上，Quenouille (1949) 证明了对于AR(p)过程，当 $k > p$ 时， $\hat{\phi}_{kk}$ 近似服从均值为0，方差为 $1/n$ 的正态分布，所以其在正负两倍标准差 $\pm 2/\sqrt{n}$ 之间的概率约为0.95.

$$P\left(-\frac{2}{\sqrt{n}} \leq \hat{\phi}_{kk} \leq \frac{2}{\sqrt{n}}\right) \approx 0.95$$

# AR(1)模型识别范例


Exhibit 6.10 Sample ACF for an AR(1) Process with  $\phi = 0.9$



```
> data(ar1.s); acf(ar1.s,xaxp=c(0,20,10))
```

# AR(1)模型识别范例

Exhibit 6.11 Sample Partial ACF for an AR(1) Process with  $\phi = 0.9$




```
> pacf(ar1.s,xaxp=c(0,20,10))
```



# AR(2)模型识别范例


Exhibit 6.12 Sample ACF for an AR(2) Process with  $\phi_1 = 1.5$  and  $\phi_2 = -0.75$



```
> acf(ar2.s,xaxp=c(0,20,10))
```

# AR(2)模型识别范例

Exhibit 6.13 Sample PACF for an AR(2) Process with  $\phi_1 = 1.5$  and  $\phi_2 = -0.75$



```
> pacf(ar2.s,xaxp=c(0,20,10))
```


# ARMA模型识别和EACF

- EACF: 滤出AR部分, 剩下MA部分, 余下部分ACF截尾。
- 经过 $j + 1$ 次回归, 得到了 $Y_{t-1}, \dots, Y_{t-k}$ 的系数 $\tilde{\phi}_1, \dots, \tilde{\phi}_k$ ,  
令 $W_{t,k,j} = Y_t - \tilde{\phi}_1 Y_{t-1} - \dots - \tilde{\phi}_k Y_{t-k}$
- 如果真实模型为ARMA(p, q), 对于 $k = p, j \geq q$ ,  $\{W_{t,k,j}\}$ 近似是MA(q)模型, 所以其ACF序列 $q$ 阶截尾。
- 若 $\{W_{t,k,j}\}$ 的 $j + 1$ 阶样本ACF显著不为0, 则EACF表的第 $k$ 行第 $j$ 列标为“x”, 否则标为“o”
- 当 $k > p$ 时,  $\{W_{t,k,j}\}$ 的MA阶数同步增加。
- 问答: EACF图的第 $k$ 行代表什么? 怎么解释?

# 例一：白噪声

- 对于白噪声序列 $\{e_t\}$ ，假设它的AR部分为0阶，则无论做几次回归都有 $W_{t,0,j} = e_t$ ，ACF为0阶截尾。
- 如果假设它的AR部分为1阶，则无论做几次回归， $\{W_{t,1,j}\}$ 都满足MA(1)模型，ACF为1阶截尾。
- 如果假设它的AR部分为k阶，则无论做几次回归， $W_{t,k,j} = e_t - \tilde{\phi}_1 e_{t-1} - \dots - \tilde{\phi}_k e_{t-k}$ 都满足MA(k)模型，ACF为k阶截尾。
- 所以白噪声的EACF表的第k行从第k列开始大概率为“o”，但是也有意外情况，如果该白噪声的样本ACF在第q阶显著不为0，则EACF表的第q-1列会出现一定的“x”，这是EACF表中常见的一种现象。

# 例一：白噪声




```
> eacf(x)
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 0 0 0 0 x 0 0 0 0 0 0 0 0 0
1 0 0 0 0 x 0 0 0 0 0 0 0 0 0
2 x x 0 0 x 0 0 0 0 0 0 0 0 0
3 x x x 0 x 0 0 0 0 0 0 0 0 0
4 x x x x x 0 0 0 0 0 0 0 0 0
5 x x x x x 0 0 0 0 0 0 0 0 0
6 x x x x x 0 0 0 0 0 0 0 0 0
7 x x x x x 0 0 0 0 0 0 0 0 0
```

## 例二：ARMA(2, 2)

- 对于ARMA(2, 2)序列 $\{Y_t\}$ ，当 $k = 0, 1$ 时，做回归无法有效去除AR部分，所以ACF无明显截尾。
- EACF的第2行有什么特点？
- EACF的第 $k$ 行有什么特点？
- EACF表中的“o”大致呈现出以第2行第2列为“顶点”的三角模式。

## 例二：ARMA(2, 2)



```
> eacf(y)
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 x x o x x o o o o o o o o o
1 x x o x x o o o o o o o o o
2 x x o o o o o o o o o o o o
3 o o x o o o o o o o o o o o
4 x o x o o o o o o o o o o o
5 x x o o o o o o o o o o o o
6 x x x o o o o o o o o o o o
7 x x x x o o o o o o o o o o
```

# 非平稳模型识别


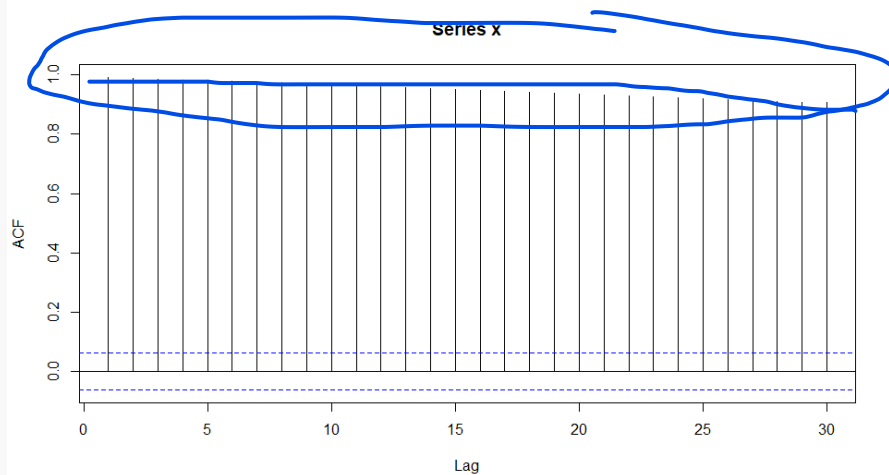


- 当样本ACF呈现出缓慢下降的趋势时，我们可以尝试对原序列进行一次差分，对差分后的序列观察ACF、PACF、EACF等，尝试建立平稳模型。
- 如果一次差分后的样本ACF仍然缓慢下降，可以考虑再次差分，但为了避免过度差分，建议仔细查看每次差分后的序列本身及其自相关特性：模型尽量简洁，但也不能草率。
- 可以结合数据实际背景做变换，如对数差分变换，Box-Cox变换等。



# 例：确定趋势vs随机趋势

$$X_t = 0.05t + e_t$$


$$Y_t = Y_{t-1} + e_t$$





# 例：确定趋势vs随机趋势

$$\nabla X_t = 0.05 + e_t - e_{t-1}$$


$$\nabla Y_t = e_t$$



Series diff(x)



Series diff(y)



# ARMA模型参数估计

- 矩估计
- 最小二乘估计
- 最大似然估计

# 待估参数

- 估计对象为差分后的平稳模型：
- $$Y_t - \mu = \phi_1(Y_{t-1} - \mu) + \cdots + \phi_p(Y_{t-p} - \mu) + e_t - \theta_1 e_{t-1} - \cdots - \theta_q e_{t-q}$$
- 待估参数为：
- 均值  $\mu$
- AR系数  $\phi_1, \phi_2, \cdots, \phi_p$ ，MA系数  $\theta_1, \theta_2, \cdots, \theta_q$
- 白噪声的方差  $\sigma_e^2$
- 一共  $p + q + 2$  个参数

# 矩估计

- 什么是矩?
  - 均值, 方差, 协方差, 相关系数, 高阶矩等
- 矩估计, 就是用样本矩估计理论矩, 然后用相应的对应关系 (函数、方程) 等估计参数。
- 用样本均值估计理论均值,  $\hat{\mu} = \bar{Y}$ , 用样本方差估计理论方差,  $\hat{\gamma}_0 = S^2$

# Yule-Walker估计

假设拟合模型为AR(p)，用 $r_k$ 替换 $\rho_k$

$$\begin{aligned}r_1 &= \phi_1 + \phi_2 r_1 + \cdots + \phi_p r_{p-1} \\r_2 &= \phi_1 r_1 + \phi_2 + \cdots + \phi_p r_{p-2} \\&\vdots \\r_p &= \phi_1 r_{p-1} + \phi_2 r_{p-2} + \cdots + \phi_p\end{aligned}$$

通过解方程，得到估计 $\hat{\phi}_1, \hat{\phi}_2, \cdots, \hat{\phi}_p$

# MA矩估计

- MA(1),  $\rho_1 = -\frac{\theta}{1+\theta^2}$ , 替换后得  $r_1 = -\frac{\theta}{1+\theta^2}$ , 解得
- $\hat{\theta} = -\frac{1}{2r_1} \pm \sqrt{\frac{1}{4r_1^2} - 1}$ , 只有一个满足可逆条件  $|\hat{\theta}| < 1$
- $$\rho_k = \begin{cases} 1, & k = 0 \\ \frac{-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}}{1 + \theta_1^2 + \dots + \theta_q^2}, & 1 \leq k \leq q \\ 0, & k > q \end{cases}$$
- 方程组可能没有实数解! 且估计误差较大!

# ARMA矩估计

- $\rho_k = \frac{(1-\theta\phi)(\phi-\theta)}{1-2\theta\phi+\theta^2} \phi^{k-1}, k \geq 1$
- 注意到  $\frac{\rho_2}{\rho_1} = \phi$ , 因此  $\hat{\phi} = \frac{r_2}{r_1}$ , 也可以是任意的  
 $\hat{\phi} = \frac{r_{k+1}}{r_k}, k \geq 1$
- 再用  $r_1 = \frac{(1-\theta\hat{\phi})(\hat{\phi}-\theta)}{1-2\theta\hat{\phi}+\theta^2}$  解得  $\theta$



# 噪声方差估计

■ 同理，只要有公式，就能估计

■ 如MA(q),  $\gamma_0 = (1 + \theta_1^2 + \dots + \theta_q^2)\sigma_e^2$ , 故

$$\hat{\sigma}_e^2 = \frac{S^2}{(1 + \hat{\theta}_1^2 + \dots + \hat{\theta}_q^2)}$$

■ 如AR(p),  $\gamma_0 = \frac{\sigma_e^2}{1 - \phi_1\rho_1 - \phi_2\rho_2 - \dots - \phi_p\rho_p}$ , 故

$$\hat{\sigma}_e^2 = S^2(1 - \hat{\phi}_1r_1 - \hat{\phi}_2r_2 - \dots - \hat{\phi}_pr_p)$$

■ 如ARMA(1, 1),  $\gamma_0 = \frac{1 - 2\theta\phi + \theta^2}{1 - \phi^2} \sigma_e^2$ , 故  $\hat{\sigma}_e^2 = \frac{1 - \hat{\phi}^2}{1 - 2\hat{\theta}\hat{\phi} + \hat{\theta}^2} S^2$

# 矩估计特点

- 通常要估计多少个参数，就需要多少个样本矩
- 不唯一
- 优点：思想简单，易计算，不需要假设总体分布
- 缺点：只用到几个样本矩信息，信息损失，估计误差大，特别对于含有MA项的模型。

# 最小二乘估计

- 使得残差平方和 $\sum_{t=p+1}^n e_t^2$ 最小的那组参数即为最小二乘估计。
- 带均值AR(1)模型,  $Y_t - \mu = \phi(Y_{t-1} - \mu) + e_t$ , 残差平方和为

$$S_c(\phi, \mu) = \sum_{t=2}^n [Y_t - \mu - \phi(Y_{t-1} - \mu)]^2$$

- 该平方和称为条件平方和函数, 最小化该函数将得到最小二乘估计。
- 通常, 可以通过求偏导来完成。
- 可以发现, 当 $n$ 较大时, 估计值非常接近Yule-Walker矩估计。

# MA(1)模型的最小二乘估计

- 考虑零均值模型  $Y_t = e_t - \theta e_{t-1}$ ，可变形为  $e_t = Y_t + \theta e_{t-1}$ ，如果令  $e_0 = 0$ ，则  $e_1 = Y_1$ ， $e_2 = Y_2 + \theta e_1$ ， $\dots$ ， $e_n = Y_n + \theta e_{n-1}$ ，需要最小化的函数为  $S_c(\theta) = \sum_{t=1}^n e_t^2$ 。
- 当  $|\theta| < 1$  时，模型可逆， $e_0$  的选取对估计的影响微乎其微。
- 当给定  $\theta$  的值时， $S_c(\theta)$  可直接算出来，但是难以求极值，可以通过网格遍历区间  $(-1, 1)$  来求解最优值。

# MA(q)模型的最小二乘估计

- $Y_t = e_t - \theta_1 e_{t-1} - \cdots - \theta_q e_{t-q}$  可以写成

$$e_t = Y_t + \theta_1 e_{t-1} + \cdots + \theta_q e_{t-q}$$

- 令  $e_0 = e_{-1} = \cdots = e_{1-q} = 0$ , 则  $e_1 = Y_1$ , 递推求出  $e_t$  的值, 再最小化  $S_c(\theta_1, \dots, \theta_q) = \sum_{t=1}^n e_t^2$ .
- 只能用数值优化算法求解, 一般统计软件都有内置。

# ARMA(p, q)模型的最小二乘估计

- $Y_t = \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + e_t - \theta_1 e_{t-1} - \cdots - \theta_q e_{t-q}$  可以写成

$$e_t = Y_t - \phi_1 Y_{t-1} - \cdots - \phi_p Y_{t-p} + \theta_1 e_{t-1} + \cdots + \theta_q e_{t-q}$$

- 令  $e_p = e_{p-1} = \cdots = e_{p+1-q} = 0$ , 则  $e_{p+1} = Y_{p+1} - \phi_1 Y_p - \cdots - \phi_p Y_1$ , 递推求出  $e_t$  的值, 再最小化  $S_c(\theta_1, \dots, \theta_q) = \sum_{t=p+1}^n e_t^2$ .

# 最大似然估计

- 使得似然函数（等于概率密度函数）最大的参数值就是最大似然估计。

$$L(\boldsymbol{\theta}|Y_1, \dots, Y_n) = f(Y_1, \dots, Y_n|\boldsymbol{\theta})$$

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}} L(\boldsymbol{\theta}|Y_1, \dots, Y_n)$$

# AR(1)模型的最大似然估计

- 假设白噪声为正态分布 $N(0, \sigma_e^2)$ ，其密度函数为

$$(2\pi\sigma_e^2)^{-1/2} \exp\left(-\frac{e_t^2}{2\sigma_e^2}\right)$$

- 则 $e_2, \dots, e_n$ 的联合概率密度为

$$(2\pi\sigma_e^2)^{-(n-1)/2} \exp\left(-\frac{1}{2\sigma_e^2} \sum_{t=2}^n e_t^2\right)$$

- 代入 $e_t = Y_t - \mu - \phi(Y_{t-1} - \mu)$ 可得

$$(2\pi\sigma_e^2)^{-(n-1)/2} \exp\left(-\frac{1}{2\sigma_e^2} \sum_{t=2}^n [Y_t - \mu - \phi(Y_{t-1} - \mu)]^2\right)$$

- 问答：这是什么的密度函数？



# AR(1)模型的似然函数

- 乘上初始值 $Y_1 \sim N(\mu, \frac{\sigma_e^2}{1-\phi^2})$ 的概率密度, 得到 $Y_1, \dots, Y_n$ 的联合概率密度, 亦即我们要的似然函数

$$L(\phi, \mu, \sigma_e^2 | Y_1, \dots, Y_n) = (2\pi\sigma_e^2)^{-\frac{n}{2}} (1 - \phi^2)^{1/2} \exp\left(-\frac{1}{2\sigma_e^2} S(\phi, \mu)\right)$$

$$S(\phi, \mu) = (1 - \phi^2)(Y_1 - \mu)^2 + \sum_{t=2}^n [Y_t - \mu - \phi(Y_{t-1} - \mu)]^2$$

对数似然函数为 $\log L(\phi, \mu, \sigma_e^2 | Y_1, \dots, Y_n) =$

$$l(\phi, \mu, \sigma_e^2 | Y_1, \dots, Y_n) = -\frac{n}{2} \log(2\pi\sigma_e^2) + \frac{1}{2} \log(1 - \phi^2) - \frac{1}{2\sigma_e^2} S(\phi, \mu)$$

# 无条件平方和与简化估计

$$\begin{aligned} l(\phi, \mu, \sigma_e^2 | Y_1, \dots, Y_n) \\ = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_e^2) + \frac{1}{2} \log(1 - \phi^2) \\ - \frac{1}{2\sigma_e^2} S(\phi, \mu) \end{aligned}$$

- $S(\phi, \mu) = S_c(\phi, \mu) + (1 - \phi^2)(Y_1 - \mu)$ , 称为无条件平方和函数, 简化起见, 我们可以最小化函数  $S(\phi, \mu)$ , 得到  $\hat{\phi}, \hat{\mu}$ , 而对  $\sigma_e^2$  求偏导可以发现:

$$\hat{\sigma}_e^2 = \frac{S(\hat{\phi}, \hat{\mu})}{n}$$